

5.Hafta

Lineer Regresyon (Eğri Uydurma)

Lineer Regresyon (Eğri Uydurma)


- Bütün makine öğrenmesi uygulamaları aynı genel yöntemi takip eder:
 - Bir olayın modeli için ve bir başarı ölçümü için, önceden var olan verilerden olayın uygun modeli bulmak, ve gelecekteki kararlar için bu modeli kullanmak
- Farklı makine öğrenmesi yöntemleri, farklı olay modelleri kullanabilmektedir
- Bunlardan, **lineer regresyon modeli** en basit makine öğrenmesi modelidir

Lineer Regresyon

- Lineer regresyon modelinde, neden ve sonuç arasında lineer ilişki varsayılmaktadır

Lineer Regresyon


- Reklam harcamalarına bağlı gelecek öğrenci sayısı



Lineer Regresyon

- Reklam harcamalarına bağlı gelecek öğrenci sayısı


Lineer ilişki



Lineer Regresyon


Bu model için mümkün makine öğrenme amaçları:

- Gelecek öğrenci sayısını tahmin etmek
- Gereken reklam harcamasını belirtmek



Lineer Regresyon


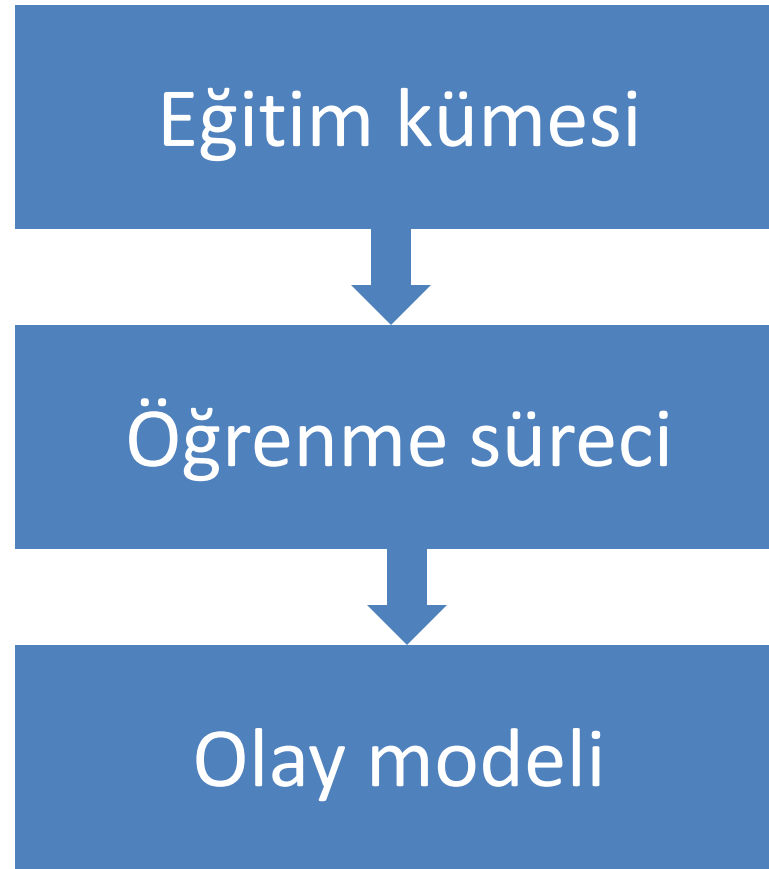
- Geçen senelerden yada benzer kurumlardan veriler var, yani hem de reklam harcamaları hem de sonuç olarak geldiği öğrenci sayısı var;
- Bu karar modeli, denetimli öğrenme kullanarak öğrenebilir



Lineer Regresyon

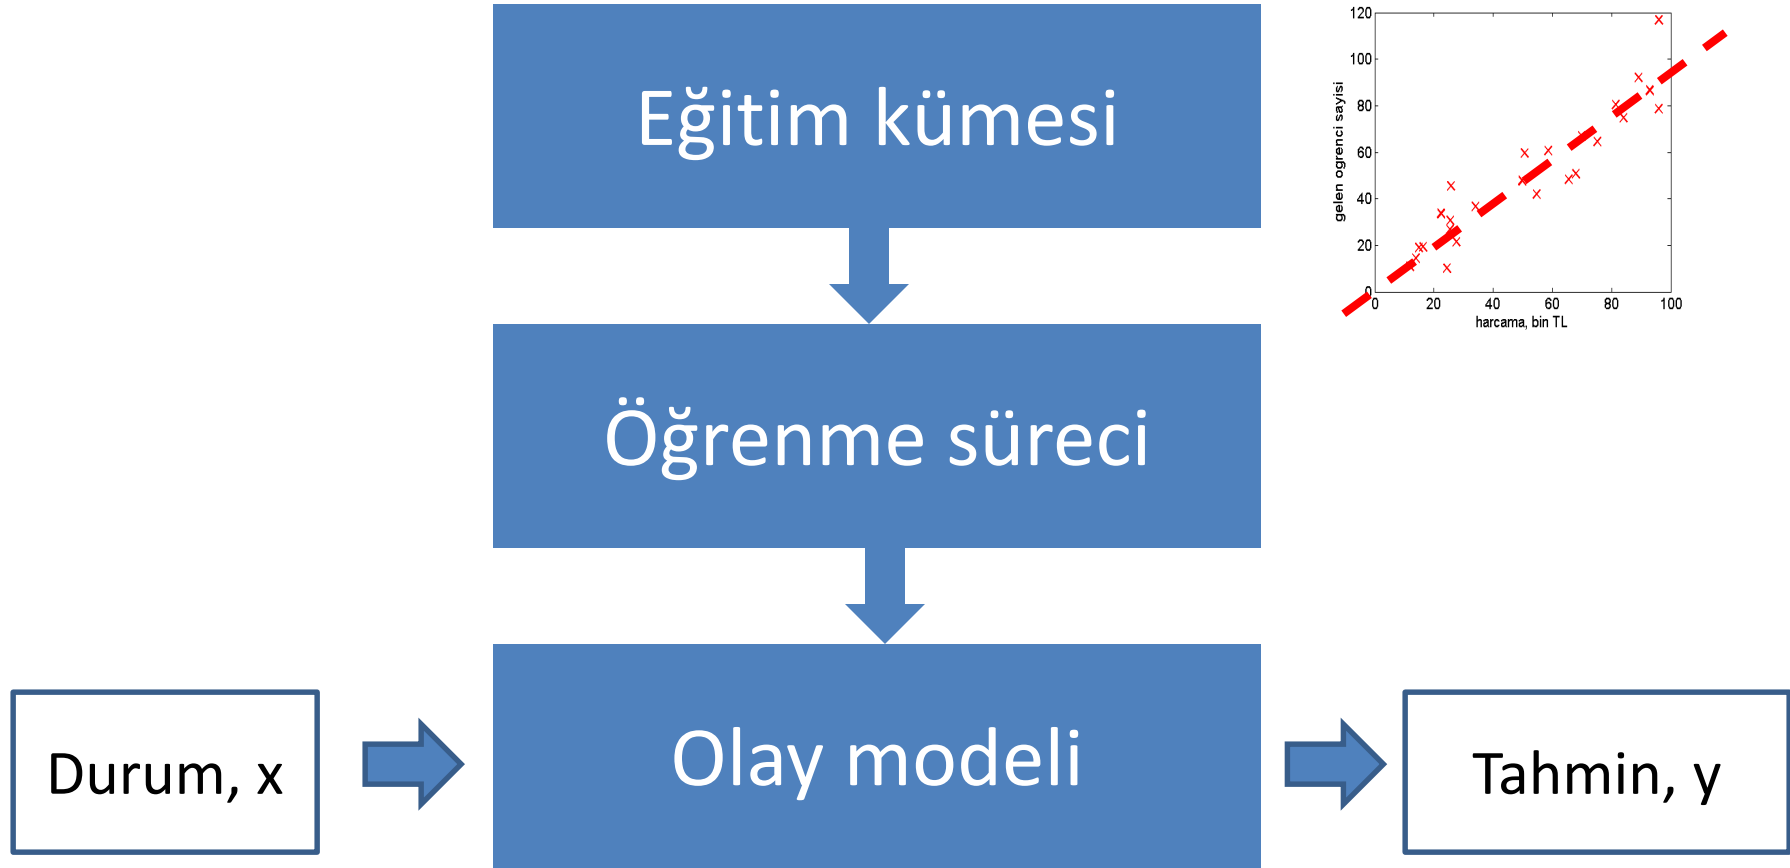
- Notasyon (burada ve daha sonra sürekli kullanılır olacak)
 - “ m ”, önceden var olan örneklerin sayısı
 - Önceden bütün var olan örneklerle “eğitim kümesi” diyoruz
 - “ x ”, girdi değişkeni, bağımsız değişken, açıklayıcı değişken, yada neden faktörü, örneğin – reklam harcamaları
 - “ y ”, çıktı değişkeni, bağımlı değişken, yada sonuç, örneğin – geldiği öğrenci sayısı
 - (x, y) – bir örnek, yani “ x ” ve “ y ” çifti
 - (x^i, y^i) – eğitim kümesindeki “ i ” numaralı bir tane örnek

Makine öğrenme sorunu



$$h(x)$$

Lineer Regresyon



$$y=h(x)$$

ilişki fonksiyonu

Lineer Regresyon

- “ $h(x)$ ” fonksiyonuna **hipotez** denir
- Demek ki, olayın modeli yada x ve y arasında olabilir ilişki fonksiyonu için belli bir şekili hipotez olarak varsayıyoruz

Lineer Regresyon

- Örneğin, en basit model/hipotezi,

$$y = h_{\theta}(x) = \theta_0 + \theta_1 \cdot x$$

(bu model/hipoteze **lineer model/hipotezi** denir)

Lineer Regresyon

- Hipotez fonksiyonu birkaç ya da birçok parametreye bağlı olmalıdır

$$y = h_{\theta}(x) = \theta_0 + \theta_1 \cdot x$$

parametreler



Lineer Regresyon

- Öğrenme sürecinin uygun modeli oluşturması, eğitim kümesini kullanarak hipotez fonksiyonunun uygun parametrelerini seçmek demektir

$$y = h_{\theta}(x) = \theta_0 + \theta_1 \cdot x$$

parametreler



Lineer Regresyon

- Önceden var olan verilere göre hipotezdeki uygun parametreleri seçince, olayın modeli belirli olup gelecekte farklı kararlar için sonuçlarının tahmin edileceği için kullanılabilir

$$y = h_{\theta}(x) = \theta_0 + \theta_1 \cdot x$$

Kararın sonucu

Mümkün karar

Maliyet fonksiyonu

- Hipotez parametreleri iyi şekilde nasıl seçilebilir?
- Öncelikle, “iyi parametre seçilmesi” ne demektir???
- Bunun için bir maliyet fonksiyonu kullanılır
- Bizim sorunumuza tekrar bakalım

Maliyet fonksiyonu


- Farklı modellerin uygunluğu kesinleştirmek için, **maliyet fonksiyonu** kullanılmaktadır
- Maliyet fonksiyonu, bir modelin var olan verilere uygunluğu ya da iyiliği belirtir

Maliyet fonksiyonu

Aynı eğitim kümesi için birkaç hipotez denilebilir:

$$\theta_0=10 \quad \theta_1=0$$

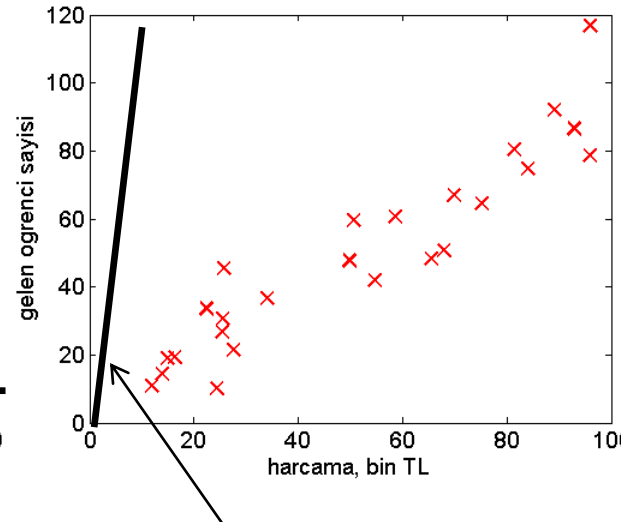
$$y=h(x)=10$$



model

$$\theta_0=0 \quad \theta_1=10$$

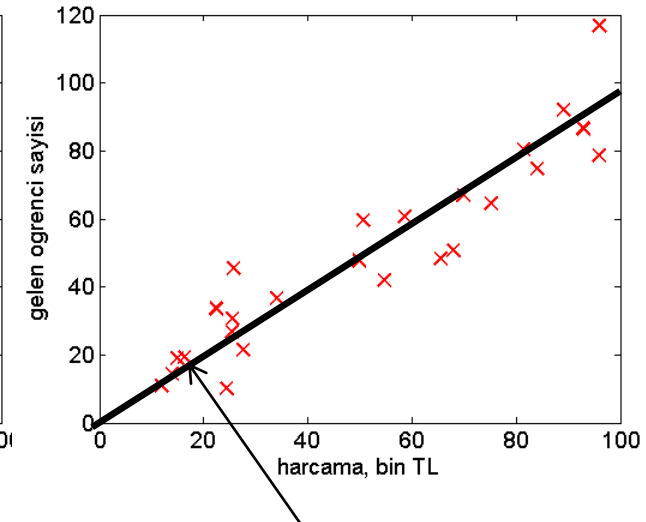
$$y=h(x)=10*x$$



model

$$\theta_0=0 \quad \theta_1=1$$

$$y=h(x)=1*x$$



model

Maliyet fonksiyonu

- İyi hipotez için, model olan y 'ler eğitim kümedeki y 'lere **yakın olacağını** istemekteyiz
- Bu ölçüde, (θ_0, θ_1) model parametreleri, model y 'lerinin gerçek var olan verilere en yakın olacağını sağlamak zorundadır

Maliyet fonksiyonu


- Model y'lerinin gerçek verilerden uzaklığı ölçmek için, şu fonksiyon kullanılabilir

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$

Maliyet fonksiyonu

Bir örnek için aralığı:

$$\frac{h_{\theta}(x^i) - y^i}{}$$





Aralıklar büyük ise,
model kötü demektir,
ve J maliyeti de çok
büyük olacaktır

Maliyet fonksiyonu

- Bu durumda, J fonksiyonuna “**maliyet fonksiyonu**” diyoruz
- Maliyet fonksiyonu, farklı modellerin gerçek verilere ne kadar yakın olduğunu tanımlıyor
- **Büyük J 'nin değerleri**, $h_{\theta}(x)$ değerlerinin gerçek verilerden **çok uzak olduğunu** demektir

Maliyet fonksiyonu

En iyi model, gerçek verilere en yakın model,
böylece en küçük J değeri demektir



Maliyet fonksiyonu

- Modelin gerçek verilere en yakın olacağını sağlamak, (θ_0, θ_1) için bu optimizasyon problemi demektedir

$$\min_{\theta} J(\theta) = \min_{\theta_0, \theta_1} \underbrace{\frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2}_{\text{Modeldeki sonuçların gerçek verilerden ortalama mesafesi}}$$

Modeldeki sonuçların gerçek verilerden ortalama mesafesi

Maliyet fonksiyonu

Gerçek lineer regresyon maliyeti iki parametreye bağlı, yani 2 boyutlu fonksiyondur

